

Incertidumbre 3: Razonamiento Probabilístico

Representación Numérica de la Incertidumbre: Probabilidad

- **La Teoría de la Probabilidad (TProb)**

- Es un área de las Matemáticas que ha sido aplicada a problemas de razonamiento con incertidumbre
- Es una **teoría elegante, bien entendida y con mucha historia** (formalizaciones a partir de mediados del siglo XVII)
- Asigna **valores numéricos** (llamados probabilidades) a las proposiciones.
- Nos dice, dadas las probabilidades de ciertas proposiciones, y algunas relaciones entre ellas como asignar probabilidades a las proposiciones relacionadas
- Relación con la LPO:
 - En la LPO las proposiciones son ciertas o falsas.
 - Con la Tprob las proposiciones son también ciertas o falsas pero se tiene un grado de creencia en la certeza o falsedad.

¿Qué son las Probabilidades?

- **A pesar de su larga historia los valores numéricos que representan las probabilidad no tiene una interpretación única.**
- **Algunas Interpretaciones:**
 - **Frecuentista:** Es el valor, cuando el número de pruebas tiende a infinito, de la frecuencia de que ocurra algún evento
 - **Subjetiva:** Es un grado de creencia acerca de un evento incierto
- **Aún así:**
 - Existe un consenso sobre el modelo matemático que soporta la Teoría

Los Valores Numéricos de la Probabilidad

- **Denotaremos por $P(A)$ a la probabilidad de la proposición A**
 - A ="El paciente tiene sarampión"
 - A ="Mañana saldrá el sol" ...
- **Los valores de la Probabilidad satisfacen un conjunto de **axiomas**:**
 - $0 \leq P(A) \leq 1$
 - $P(\text{Proposición Verdadera})=1$
 - $P(A \vee B)=P(A)+P(B)$
 - Siempre que A y B sean disjuntos, es decir $\neg(A \wedge B)$
- **A partir de ellos se puede demostrar por ejemplo:**
 - $P(\neg A)=1-P(A)$
 - $P(\text{Proposición Falsa})=0$
 - $P(A \vee B)=P(A)+P(B)-P(A \wedge B)$

Variables Aleatorias

- **Muchas veces tenemos un evento con un conjunto de resultados:**

- **Completo**

- Se conocen **todos** los posibles resultados

- **Mutuamente excluyente**

- No se pueden dar dos resultados distintos **simultáneamente**.

Ejemplos

- Si tiramos una moneda, el resultado es cara o cruz
 - Si tiramos un dado, se producen seis resultados distintos
 - La temperatura de un paciente puede estar en un conjunto de intervalos: <36.5 , $36.5-37.4$, $37.5-38.4$, $38.5-39.4$, >39.4
- **En lugar de tener una proposición para cada resultado se introduce el concepto de **Variable aleatoria****
- **Se permiten proposiciones de la forma **Variable = resultado****
 - Por ejemplo, si M ="Resultado de tirar una moneda con valores posibles cara y cruz" se permiten las proposiciones:
 - $M=\text{cara}$ y $M=\text{Cruz}$ y podemos hablar de
 - $P(M=\text{cara})$ y $P(M=\text{cruz})$ que representan la probabilidad de obtener una cara y una cruz respectivamente

Variables Aleatorias

- **Por consistencia, se puede considerar que **todas las proposiciones son variables aleatorias** que toman dos valores verdadero o falso**
 - Por ejemplo, dada la proposición “Tiene Sarampión”
 - Construimos la variable aleatoria Sarampión que toma los valores verdadero y falso
 - Y representamos la probabilidad de que un paciente tenga Sarampión $P(\text{“Tiene Sarampión”})$ como $P(\text{Sarampión} = \text{verdadero})$
- **Abreviaturas**
 - Se suele escribir $P(M = \text{cara})$ como $P(\text{cara})$, cuando está claro que nos referimos a la variable aleatoria M .
 - Si una variable aleatoria como Sarampión toma únicamente los valores verdadero o falso se suele escribir $P(\text{Sarampión} = \text{verdadero})$ como $P(\text{sarampión})$ y $P(\text{Sarampión} = \text{falso})$ como $P(\neg \text{sarampión})$

Distribuciones de Probabilidad

- Dada una **Variable Aleatoria** nos gustaría conocer la probabilidad para **cada** valor que pueda tomar
- Esta descripción se llama **distribución de probabilidad** (Dprob) de la variable aleatoria y consiste en listar los valores de probabilidad para cada valor de la variable
- **Ejemplo:**
 - Distribución de probabilidad de la variable Llueve

The diagram illustrates the process of determining probabilities for a variable. On the left, the word 'Variable' has an arrow pointing to the first column of a table. Below it, the word 'Valores' has two arrows pointing to the two rows of the table. To the right of the table, a double-headed arrow points from the second column to the word 'Probabilidades'.

Llueve	$P(\text{Llueve})$
Verdadero	0.1
Falso	0.9

Proposiciones más Complejas

- **Podemos estar interesados en estudiar varias variables en conjunto.**
 - Por ejemplo
 - $P(\text{Sarampión}=\text{verdadero} \wedge \text{Fiebre}=\text{verdadero})$ que es la probabilidad de que el paciente tenga sarampión y fiebre
 - Generalmente lo escribiremos como:
 - $P(\text{sarampión} \wedge \text{fiebre})$ o $P(\text{sarampión}, \text{fiebre})$
- **Para ello se necesita asignar probabilidades a cada posible combinación de los valores de las variables.**
- **El listado de todos esos valores se llama la distribución conjunta del conjunto de variables**

Ejemplo de distribución conjunta

- **Distribución conjunta** de las variables **Llueve** y **EnCalle**
 $P(\text{Llueve}, \text{EnCalle})$:

Llueve	EnCalle	$P(\text{Llueve}, \text{EnCalle})$
Verdadero	Verdadero	0.01
Verdadero	Falso	0.09
Falso	Verdadero	0.2
Falso	Falso	0.7

- **También se puede escribir como:**

Llueve	EnCalle	$P(\text{Llueve}, \text{EnCalle})$
llueve	encalle	0.01
llueve	\neg encalle	0.09
\neg llueve	encalle	0.2
\neg llueve	\neg encalle	0.7

- **Recuerda a la tabla de la verdad lógica excepto que:**
 - Describe las probabilidad para cada combinación de valores de las variables
 - Generalmente dichos valores no se pueden calcular a partir de sus componentes

La Importancia de la Distribución Conjunta


- La distribución conjunta contiene **todo lo que se necesita saber acerca** de un conjunto de variables aleatorias.
- En particular, la distribución de cada variable individual se puede calcular a partir de la distribución conjunta (y se llama **distribución marginal**)
 - Ejemplo: Supongamos las variables aleatorias: Llueve y EnCalle con distribución conjunta $P(\text{Llueve}, \text{EnCalle})$

llueve	encalle	0.01
llueve	¬encalle	0.09
¬ llueve	encalle	0.2
¬ llueve	¬encalle	0.7

- Entonces $P(\text{llueve}) = P(\text{llueve} \wedge \text{enCalle}) + P(\text{llueve} \wedge \neg \text{enCalle}) = 0.01 + 0.09 = 0.1$.
- De forma similar $P(\neg \text{llueve}) = 0.9$
- También podemos calcular la probabilidad de disyunciones:
 $P(\text{llueve} \vee \text{enCalle}) = 0.01 + 0.09 + 0.2 = 0.3$

Probabilidad Condicional

- Escribiremos $P(A | B)$ para representar la probabilidad de A dado B. Esta probabilidad se llama **probabilidad condicional**.
- Lo podemos interpretar como **mi grado de creencia en A cuando todo lo que sé es B**.
 - O de forma alternativa, de los casos en los que se da B, ¿en que proporción se da A?



Probabilidad Condicional
Representación gráfica

- **Se define como:**
 - $P(A|B) = P(A \cap B) / P(B)$ (Asumiendo $P(B) \neq 0$) o equivalentemente
 - $P(A \cap B) = P(A|B)P(B)$ (Regla del Producto)

Distribución Condicional

- **Nos permite conocer la probabilidad de que se tomen unos determinados valores por un conjunto de variables aleatorias cuando se saben los valores que han tomado otras.**

- Ejemplo: $P(\text{Llueve}|\text{enCalle})$

Llueve	$P(\text{Llueve} \text{enCalle})$
!lueve	0.05
\neg !lueve	0.95

- Ejemplo: $P(\text{Llueve}|\neg \text{enCalle})$


Llueve	$P(\text{Llueve} \neg \text{enCalle})$
!lueve	0.11
\neg !lueve	0.89

- Nótese que $\text{Llueve}|\text{enCalle}$ y $\text{Llueve}|\neg \text{enCalle}$ son variables aleatorias

Razonamiento con Probabilidades: La Regla de Bayes

- **Propuesta en 1763 por el Reverendo T. Bayes**

- $P(A|B) = P(B|A) P(A) / P(B)$
- Es una consecuencia de la regla del producto:
 - $P(A|B)P(B) = P(A,B) = P(B|A)P(A)$



Thomas Bayes

- **De forma intuitiva:**

- La probabilidad de una hipótesis A dada una evidencia B: $P(A|B)$ es proporcional a probabilidad de la hipótesis $P(A)$ multiplicada por el grado en que la hipótesis predice los datos $P(B|A)$

- **Aplicabilidad**

- En muchos problemas dado un conjunto de datos (evidencia) B tenemos que seleccionar la hipótesis A más probable mediante $P(A|B)$

Regla de Bayes: Forma General

- **Forma general de la Regla de Bayes**

- Si se tiene un conjunto de proposiciones $\{A_1, A_2, \dots, A_m\}$ completas y mutuamente excluyente se tiene:

$$P(A_i|B) = \frac{P(B|A_i) P(A_i)}{P(B|A_1) P(A_1) + \dots + P(B|A_n) P(A_m)}$$

O lo que es lo mismo, si tiene una variable aleatoria A con valores a_1, a_2, \dots, a_m

$$P(a_i|B) = \frac{P(B|a_i) P(a_i)}{P(B|a_1) P(a_1) + \dots + P(B|a_n) P(a_m)}$$

La Regla de Bayes: Ejemplo

- **Intentemos resolver un caso real con probabilidades:**

- Se pretende determinar la presencia o no de una enfermedad con un test.
 - En este caso:
 - Hipótesis (A): Enfermedad (variable aleatoria con dos valores verdadero y falso)
 - Evidencia (B): Test (variable aleatoria con dos valores positivo y negativo)
 - Se tiene:
 - $P(a)=1/10000$ (Prevalencia)
 - $P(b|a)=0.99$ (Sensibilidad)
 - $P(\neg b | \neg a)=0.99$ (Especificidad)
 - Aplicando la Regla de Bayes:
$$P(a|b) = \frac{P(b|a) P(a)}{P(b|a) P(a) + P(b | \neg a) P(\neg a)} = \frac{0.99 \times 0.0001}{0.99 \times 0.0001 + (1-0.99) \times (1-0.0001)} = \frac{1}{102} = 0.0098$$
$$P(\neg a | b) = 1 - 0.0098 = 0.9902$$
 - Al elegir la hipótesis más probable debemos concluir que con este test si el resultado es positivo lo más probable es que el paciente no esté enfermo!

La Regla de Bayes: Ejemplo

- **Continuamos con el ejemplo:**

- ¿Y si hay varios tests B_1, B_2, \dots, B_m ?
 - Supondremos que cada test B_1, B_2, \dots, B_m es una variable aleatoria con dos resultados: positivo y negativo.
- Entonces si queremos calcular la probabilidad de que el paciente esté enfermo necesitamos calcular:

$$P(A | B_1, B_2, \dots, B_m) = P(B_1, B_2, \dots, B_m | A) P(A) / P(B_1, B_2, \dots, B_m)$$

- Si al paciente se le hace un conjunto de 30 pruebas y por simplificar se supone que cada una da como resultado sí o no.
 - Entonces para almacenar la tabla de probabilidad conjunta $P(B_1, B_2, \dots, B_m | A)$ se necesitan guardar unos 2^{30} números reales (unos 8 DVD's por paciente).
 - ¿De donde sacamos los números? ¿Cómo estimar los números a partir de casos (en la Tierra hay 2^{32} personas aproximadamente)?
 - ¿Cómo hacemos los cálculos computacionalmente eficientes?

Independencia: ¿Una Solución?

- **Independencia**

- Decimos que dos proposiciones A_1 y A_2 son **independientes** si el conocimiento de una no cambia la probabilidad de la otra
 - Por ejemplo si
 - A_1 ="Es rubio" , A_2 ="Tiene la piel clara" , A_3 ="Lloverá mañana"
 - A_1 y A_3 son independientes A_1 y A_2 no.
- Formalmente A_1, A_2 son independientes si $P(A_1|A_2)=P(A_1)$
o de forma equivalente: $P(A_2|A_1)=P(A_2)$
o utilizando la regla del producto $P(A_1 \wedge A_2) = P(A_1) P(A_2)$
- Entonces $P(A_1 \wedge A_2 \wedge \dots \wedge A_n) = P(A_1) P(A_2) \dots P(A_n)$
Para especificar la distribución conjunta de n variables se necesitan $O(n)$ números en lugar de $O(2^n)$
- Dos **variables aleatorias son independientes** si el conocimiento del valor que toma una no cambia la probabilidad de los valores de la otra: $P(A_1=c|A_2=d) = P(A_1=c)$

Independencia Condicional

- **Pero...**

- La condición de independencia es muy restrictiva.
- Por ejemplo, los resultados de los tests en medicina no suelen ser independientes.

- **Independencia condicional**

- Se dice que dos proposiciones A_1, A_2 son independientes dada una tercera B si cuando B está presente el conocimiento de una no influye en la probabilidad de la otra: $P(A_1|A_2, B) = P(A_1|B)$
o de forma equivalente: $P(A_2|A_1, B) = P(A_2|B)$
o de forma equivalente: $P(A_1 \wedge A_2 | B) = P(A_1|B) P(A_2|B)$
 - Ejemplo:
 - A_1 ="Tengo congestión nasal" A_2 ="Tengo fiebre" A_3 ="Tengo gripe"
 - A_1 y A_2 son dependientes pero son independientes si se conoce A_3 .
- Ahora se tiene: $P(A_1 \wedge A_2 \wedge \dots \wedge A_n | B) = P(A_1|B) P(A_2|B) \dots P(A_n|B)$
 - Tenemos $O(n)$ números en lugar de $O(2^n)$

Independencia Condicional

- **Finalizamos el ejemplo:**

- ¿Y si hay varios tests B_1, B_2, \dots, B_m ?
- Como vimos, para calcular la probabilidad de que el paciente esté enfermo hay que calcular:

$$P(A | B_1, B_2, \dots, B_m) = P(B_1, B_2, \dots, B_m | A) P(A) / P(B_m, B_m, \dots, B_m)$$

- Si los tests B_1, B_2, \dots, B_m son independientes dada la enfermedad A (aproximación que suele dar buenos resultados):

$$P(B_1, B_2, \dots, B_m | A) = P(B_1 | A) P(B_2 | A) \dots P(B_m | A)$$

- El problema a resolver ya es **abordable**:

Basta calcular:

$$P(A | B_1, B_2, \dots, B_m) = P(B_1 | A) P(B_2 | A) \dots P(B_m | A) P(A) / P(B_m, B_m, \dots, B_m)$$

$$P(\neg A | B_1, B_2, \dots, B_m) = P(B_1 | \neg A) P(B_2 | \neg A) \dots P(B_m | \neg A) P(\neg A) / P(B_m, B_m, \dots, B_m)$$


$$\text{con } P(B_m, B_m, \dots, B_m) = P(B_1 | A) P(B_2 | A) \dots P(B_m | A) P(A) + P(B_1 | \neg A) P(B_2 | \neg A) \dots P(B_m | \neg A) P(\neg A)$$

Representación de la Independencia: Redes Bayesianas

- **La clave hacer factible la inferencia con probabilidades es la introducción explícita de la independencia entre variables**
- **El modelo más extendido de representación de independencias lo constituye las **Redes Bayesianas**.**
- **En este modelo se representa de forma explícita la dependencia entre variables mediante un grafo**
- **Los nodos del grafo se corresponden con variables y las dependencias se representan mediante arcos entre ellas**

Aplicación Regla de Bayes

- Ejemplo simple




Tenemos un conocimiento sobre la probabilidad de E ($P(E)$, **probabilidad a priori**). Indago y descubro que se da S. Conociendo $P(S/E)$ y $P(S/\neg E)$, ¿qué probabilidad hay ahora ($P(E/S)$ **probabilidad a posteriori**) de que se de E?

$$P(E|S) = \frac{P(S|E).P(E)}{P(S|E).P(E) + P(S|\neg E).P(\neg E)}$$

Aplicación Regla de Bayes

- **Caso simple: Probabilidad inducida por un efecto**



Se conoce $P(C)$, $P(E|C)$ y $P(E|\neg C)$,
¿Puedo calcular $P(C|E)$?

$$P(C|E) = \frac{P(E|C) * P(C)}{P(E|C) * P(C) + P(E|\neg C) * P(\neg C)}$$

Aplicación Regla de Bayes

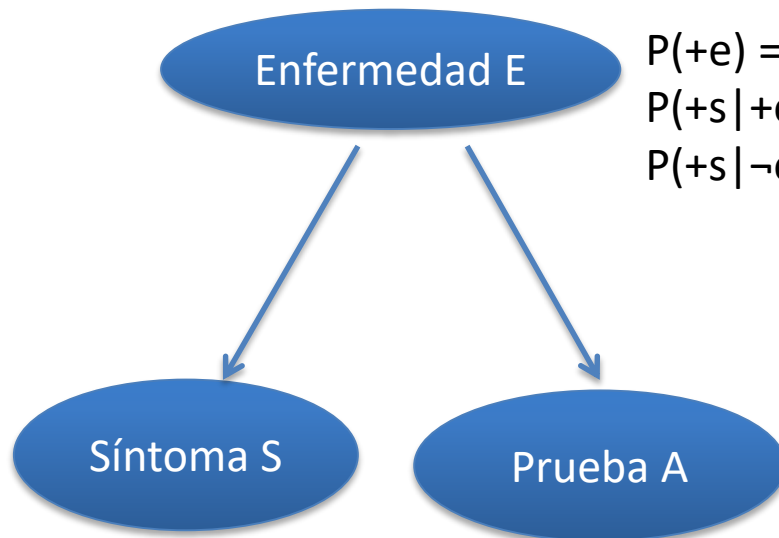
- Probabilidad inducida a una variable por varios efectos (**suponiendo independencia entre ellos cuando se condiciona a la variable**)

ENFERMEDAD (E): presente (+e), ausente (-e)

SÍNTOMA (S): presente (+s), ausente (-s)

PRUEBA ANALÍTICA (A): positivo (+a), negativo (-a)

Grafo dirigido acíclico



$P(+e) = 0'002$ → probabilidad a priori

$P(+s|+e) = 0'93$ $P(+a|+e) = 0'995$ → prob de los efectos si +e

$P(+s|-e) = 0'01$ $P(+a|-e) = 0'003$ → prob de los efectos si -e

$P(+e|+s,+a) = P(+e,+s,+a) / P(+s,+a)$ ecuación cálculo

$P(+e,+s,+a) = P(+e).P(+s|+e).P(+a|+e) = 0,00185$

$P(-e,+s,+a) = P(-e).P(+s|-e).P(+a|-e) = 0,00003$

$P(+s,+a) = P(+e,+s,+a) + P(-e,+s,+a) = 0,00188$

$P(+e|+s,+a) = P(+e,+s,+a) / P(+s,+a) = 0,984$

Red causal

- **Probabilidad inducida por varios factores (independientes entre si) y varios efectos (independientes cuando se condiciona a la variable entre si, y con los factores)**

Paludismo (X): presente +x, ausente -x


Zona de origen (F1): alto riesgo f_1^+ , riesgo medio f_1^0 , riesgo bajo f_1^-

Tipo sanguíneo (F2): mayor inmunidad f_2^+ , menor inmunidad f_1^-

Gota gruesa (E1): positivo e_1^+ , negativo e_1^-

Fiebre (E2): presente e_2^+ , ausente e_2^-

- **Grafo dirigido acíclico**



Red Causal: conocimiento

Distribución de probabilidad de los factores

$$\begin{aligned} P(f_1+) &= 0,1 \\ P(f_10) &= 0,1 \\ P(f_1-) &= 0,8 \end{aligned}$$

$$\begin{aligned} P(f_2+) &= 0,6 \\ P(f_2-) &= 0,4 \end{aligned}$$

Distribución de probabilidad condicionada de la variable con respecto a los factores

$P(+x/f_1, f_2)$	f_1+	f_10	f_1-
f_2+	0,015	0,003	0,0003
f_2-	0,022	0,012	0,0008

Distribución de probabilidad condicionada de los efectos con respecto a la variable

$$\begin{aligned} P(+e_1 | +x) &= 0,992 \\ P(+e_2 | +x) &= 0,98 \end{aligned}$$

$$\begin{aligned} P(+e_1 | -x) &= 0,006 \\ P(+e_2 | -x) &= 0,017 \end{aligned}$$

Red causal: Inferencia

$$P(f_1, f_2, x, e_1, e_2) = P(f_1) * P(f_2) * P(x | f_1, f_2) * P(e_1 | x) * P(e_2 | x)$$

- Ejemplo: calcular $P(+x | f_1^0, f_2^-, e_1^-, e_2^+)$
 - $P(f_1^0, f_2^-, +x, e_1^-, e_2^+) = P(f_1^0) * P(f_2^-) * P(+x | f_1^0, f_2^-) * P(e_1^- | +x) * P(e_2^+ | +x) =$
 $= 0,1 * 0,4 * 0,012 * 0,008 * 0,98 = 0,00000376$
 - $P(f_1^0, f_2^-, -x, e_1^-, e_2^+) = P(f_1^0) * P(f_2^-) * P(-x | f_1^0, f_2^-) * P(e_1^- | -x) * P(e_2^+ | -x) =$
 $= 0,1 * 0,4 * 0,988 * 0,994 * 0,017 = 0,00066780$
 - $P(f_1^0, f_2^-, e_1^-, e_2^+) = P(f_1^0, f_2^-, +x, e_1^-, e_2^+) + P(f_1^0, f_2^-, -x, e_1^-, e_2^+) = 0,00067156$
 - $P(+x | f_1^0, f_2^-, e_1^-, e_2^+) = P(f_1^0, f_2^-, +x, e_1^-, e_2^+) / P(f_1^0, f_2^-, e_1^-, e_2^+) =$
 $= 0,00000376 / 0,00067156 = 0,0055989 \approx 0,0056$

Red causal: deducciones

$P(+x, f_1, f_2)$	f_1^+	f_1^0	f_1^-				
f_2^+	0,0009	0,00018	0,000144	0,001224	$P(+x, f_2^+)$	0,00204	$P(+x f_2^+)$
f_2^-	0,00088	0,00048	0,000256	0,001616	$P(+x, f_2^-)$	0,00404	$P(+x f_2^-)$
	0,00178	0,00066	0,0004	0,00284	$P(+x)$		
	$P(+x, f_1^+)$	$P(+x, f_1^0)$	$P(+x, f_1^-)$				
	0,0178	0,0066	0,0005				
	$P(+x f_1^+)$	$P(+x f_1^0)$	$P(+x f_1^-)$				

- **Probabilidad a priori:** $P(+x) = 0,00284$
- **Probabilidad tras conocer los factores:** $P(+x | f_1^0, f_2^-) = 0,012$
 $P(+x | f_1^0) = 0,0066$ si desconozco el valor de F2
 $P(+x | f_2^-) = 0,0040$ si desconozco el valor de F1
- **Probabilidad tras añadir conocimiento sobre los efectos:** $P(+x | f_1^0, f_2^-, \neg e_1, e_2) = 0,0056$
Si desconozco el valor de F1 y de E2, ¿ $P(+x | f_2^-, \neg e_1)$?

Red causal: deducciones

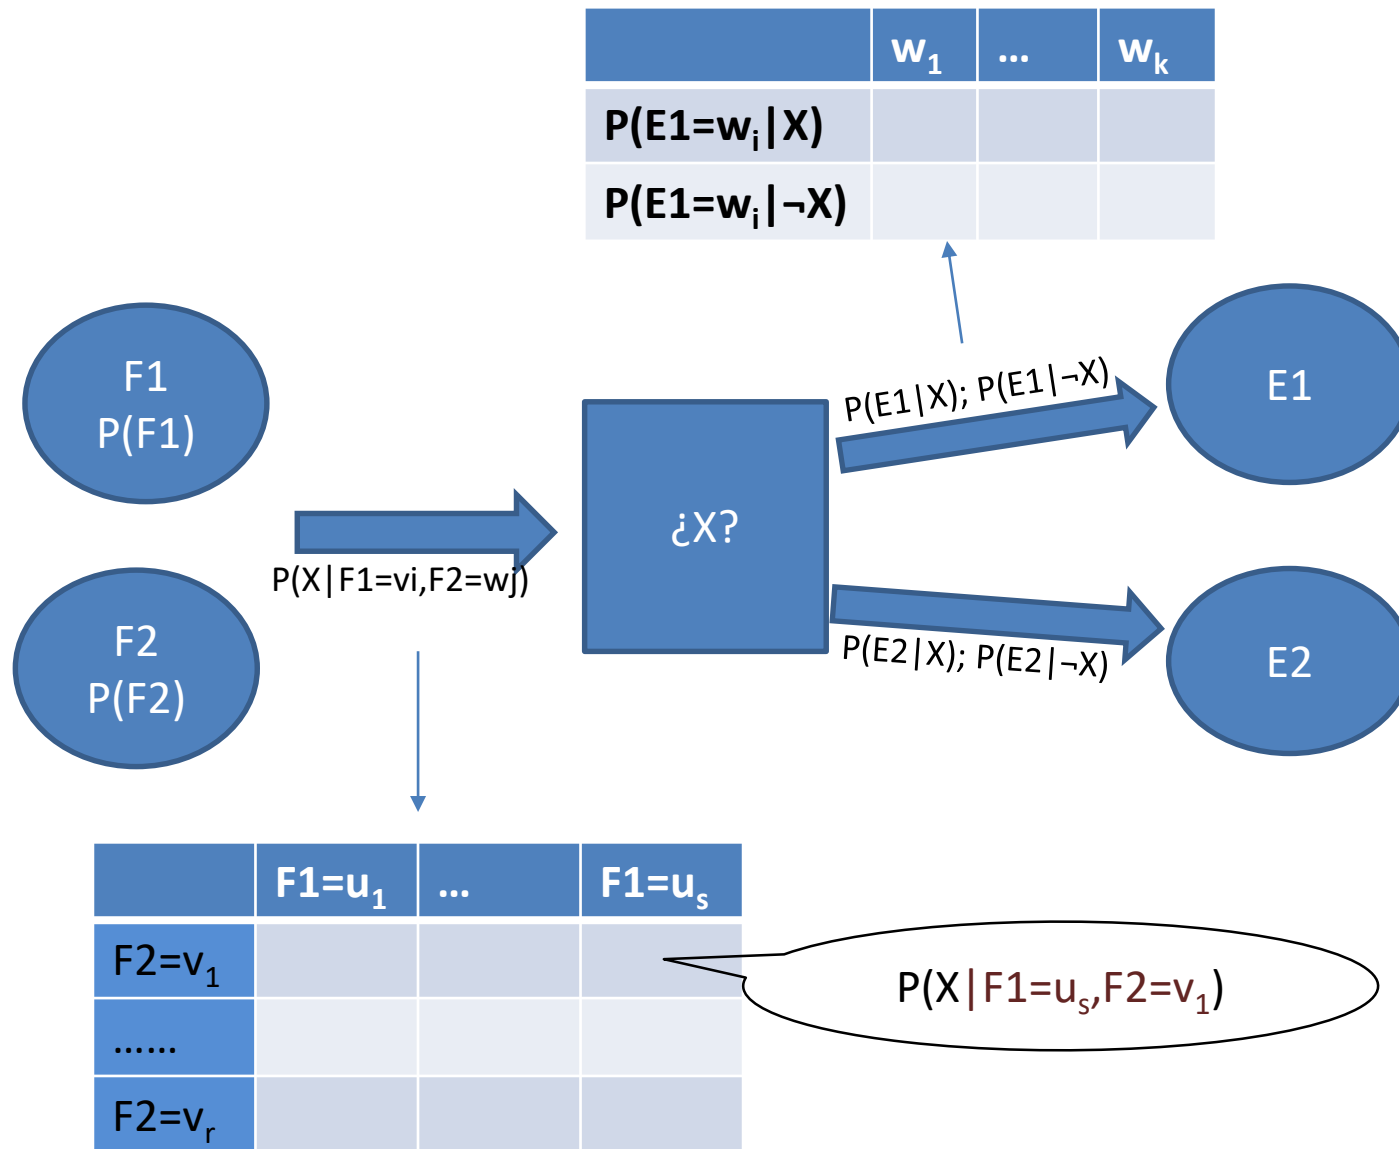
$P(+x, f_1, f_2)$	f_1^+	f_1^0	f_1^-				
f_2^+	0,0009	0,00018	0,000144	0,001224	$P(+x, f_2^+)$	0,00204	$P(+x f_2^+)$
f_2^-	0,00088	0,00048	0,000256	0,001616	$P(+x, f_2^-)$	0,00404	$P(+x f_2^-)$
	0,00178	0,00066	0,0004	0,00284	$P(+x)$		
	$P(+x, f_1^+)$	$P(+x, f_1^0)$	$P(+x, f_1^-)$				
	0,0178	0,0066	0,0005				
	$P(+x f_1^+)$	$P(+x f_1^0)$	$P(+x f_1^-)$				

$$= P(+x, f_1^+, f_2^+) + P(+x, f_1^+, f_2^-)$$

$$= P(+x | f_1^0, f_2^+) * P(f_1^0) * P(f_2^+)$$

- **Probabilidad a priori:** $P(+x) = 0,00284$
- **Probabilidad tras conocer los factores:** $P(+x | f_1^0, f_2^-) = 0,012$
 $P(+x | f_1^0) = 0,0066$ si desconozco el valor de F2
 $P(+x | f_2^-) = 0,0040$ si desconozco el valor de F1
- **Probabilidad tras añadir conocimiento sobre los efectos:** $P(+x | f_1^0, f_2^-, \neg e_1, e_2) = 0,0056$
Si desconozco el valor de F1 y de E2, ¿ $P(+x | f_2^-, \neg e_1)$?

En forma de SE (conocimiento)



En forma de SE (inferencia)

- Probabilidad a priori

$$P(X \text{ a_priori}) = P(X) = \sum P(X, F1 = ui, F2 = vj)$$

$$P(X, F1=u_i, F2=v_j) = P(F1=u_i) * P(F2=v_j) * P(X | F1=u_i, F2=v_j)$$

- Probabilidad a posteriori tras factores $F1=u, F2=v$

$$P(X \text{ a_posteriori_factores}) = P(X | F1=u, F2=v)$$

- Probabilidad a posteriori tras factores y efectos $E1=w, E2=z$

$$P(X \text{ a_posteriori_factores_efectos}) = P(X | F1=u, F2=v, E1=w, E2=z)$$

$$C_x = P(F1=u) * P(F2=v) * P(X | F1=u, F2=v) * P(E1=w | X) * P(E2=z | X) = P(X, F1=u, F2=v, E1=w, E2=z)$$

$$C_{\neg x} = P(F1=u) * P(F2=v) * P(\neg X | F1=u, F2=v) * P(E1=w | \neg X) * P(E2=z | \neg X) = P(\neg X, F1=u, F2=v, E1=w, E2=z)$$

$$C = C_x + C_{\neg x} = P(F1=u, F2=v, E1=w, E2=z)$$

$$P(X \text{ a_posteriori_factores_efectos}) = C_x / C$$

Resumen de representaciones numéricas

- **Grados de certidumbre en Mycin**

- Asigna: Un número entre -1 y 1 a cada regla
- Mide: La incertidumbre asociada a cada regla
- Aplicaciones: Sistemas Expertos
- Ventajas: El número de parámetros necesario es razonable
- Inconvenientes: Débil representación de la independencia, Incoherencias

- **Lógica difusa**

- Asigna: Un número entre 0 y 1 a cada proposición
- Mide: La verdad asociada a cada proposición
- Aplicaciones: Sistemas Expertos, Control
- Ventajas: Proporciona una forma de razonar con la vaguedad asociadas al lenguaje natural
- Inconvenientes: Tiene muchas elecciones arbitrarias (combinación de grados de creencia, inferencia, etc.)

Resumen de representaciones numéricas

- **Probabilidad**

- Asigna: Un número entre 0 y 1 a cada proposición
- Mide: La incertidumbre asociada a dicha proposición
- Aplicaciones: Sistemas Expertos, Clasificación
- Ventajas: Sistema formalmente probado y robusto
- Inconvenientes: Se necesita mucha información

IMPRECISIÓN EN LAS AFIRMACIONES VS IMPRECISIÓN EN EL CONOCIMIENTO DE LA VERACIDAD

Conocimiento verdad Afirmaciones	PRECISO	IMPRECISO: RETRACTABLE	IMPRECISO: BASADA EN ESTADISTICA	IMPRECISO: BASADO EN CREENCIAS
PRECISAS	LÓGICA CLASICA	- LÓGICA POR DEFECTO - HIPOTESIS DEL MUNDO CERRADO	PROBABILIDAD	FACTORES DE CERTEZA
IMPRECISAS	LÓGICA DIFUSA	LÓGICA DIFUSA POR DEFECTO	LÓGICA DIFUSA PROBABILISTICA	LÓGICA DIFUSA CON FACTORES DE CERTEZA